

CURS nr. 7 – TEHNICI DE SIMULARE

Simularea unor variabile aleatoare discrete.

Validarea generatorilor.

Lect. dr. Bianca Mogoș

Conținut

1. Simularea variabilelor aleatoare:

- 1.1 Bernoulli(p), $p \in (0, 1)$
- 1.2 Binomială(n, p), $n \in \mathbb{N}$, $p \in (0, 1)$
- 1.3 Geometrică(p), $p \in (0, 1)$
- 1.4 Pascal(k, p), $k \in \mathbb{N}$, $p \in (0, 1)$
- 1.5 Hipergeometrică(N, p, n), $n, N \in \mathbb{N}$, $n < N$, $p \in (0, 1)$
- 1.6 Poisson(λ), $\lambda > 0$

2. Validarea algoritmilor de simulare a unor variabile aleatoare

- 2.1 Histograma – o validare empirică a algoritmului de simulare
- 2.2 Test bazat pe momentele de selecție
- 2.3 Testul χ^2

1.1 Repartiția Bernoulli(p), $p \in (0, 1)$

- Fie un *eveniment observabil* A care are probabilitatea constantă $p = P(A) > 0$. Într-un experiment se poate produce A cu probabilitatea p sau evenimentul contrar A^C cu probabilitatea $q = 1 - p$. Un astfel de experiment se numește *probă Bernoulli*. Când se produce A spunem că s-a realizat un "succes", iar când A nu se produce spunem că avem un "eșec".

- Asociem unei probe Bernoulli variabila aleatoare Z astfel încât $Z = 1$ dacă se produce A și $Z = 0$ dacă se produce A^C . *Variabila Z are repartiția*

$$Z : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}, E[Z] = p, V(Z) = pq = p(1 - p). \quad (1)$$

Funcția de repartiție a lui Z este

$$F(x) = P(Z \leq x) = \begin{cases} 0, & \text{dacă } x < 0 \\ q, & \text{dacă } 0 \leq x < 1 \\ 1, & \text{dacă } x \geq 1 \end{cases} \quad (2)$$

1.2 Repartiția Binomială(n, p) – Algoritmi de simulare (2)

- *Simularea variabilei X se poate realiza direct*, prin numărarea de succese în n probe Bernoulli.
- Din *Teorema limită centrală* se deduce că pentru n suficient de mare ($n \rightarrow \infty$) variabila

$$W_n = \frac{X - np}{\sqrt{npq}} \quad (6)$$

este repartizată $N(0, 1)$.

1.2 Repartiția Binomială(n, p), $n \in \mathbb{N}$, $p \in (0, 1)$ (1)

- Spunem că variabila discretă $X \in \mathbb{N}$ este o *variabilă binomială* $Bin(n, p)$, $n \in \mathbb{N}^+$, $0 < p < 1$ dacă $X =$ numărul de succese în n probe Bernoulli independente, adică

$$X = \sum_{i=1}^n Z_i \quad (3)$$

unde Z_i sunt variabile identice și independent repartizate Bernoulli.

- *Repartiția variabilei binomiale X este*

$$X : \begin{pmatrix} 0 & 1 & 2 & \dots & x & \dots & n \\ q^n & npq^{n-1} & C_n^2 p^2 q^{n-2} & \dots & C_n^x p^x q^{n-x} & \dots & p^n \end{pmatrix}, \quad (4)$$

unde $q = 1 - p$.

- *Media și dispersia variabilei X sunt date de formulele*

$$E[X] = np \text{ și } Var(X) = npq. \quad (5)$$

1.3 Repartiția Geometrică(p), $p \in (0, 1)$

- Variabila X are *repartiția* $Geom(p)$, $0 < p < 1$ dacă $X =$ numărul de eșecuri până la apariția unui succes într-un șir oarecare de probe Bernoulli independente.

- *Repartiția variabilei $X \sim Geom(p)$ este*

$$X : \begin{pmatrix} 0 & 1 & 2 & \dots & x & \dots \\ p & pq & pq^2 & \dots & P(X=x) = pq^x & \dots \end{pmatrix}, q = 1 - p. \quad (7)$$

- *Funcția de repartiție a variabilei X se poate calcula cu formula*

$$F(x) = P(X \leq x) = \sum_{i=0}^x pq^i = 1 - q^{x+1}, x = 0, 1, 2, \dots \quad (8)$$

- *Media și dispersia variabilei X sunt date de formulele*

$$E[X] = \frac{q}{p} \text{ și } V(X) = \frac{q}{p^2}. \quad (9)$$

- *Interpretarea cu urnă:* $X =$ numărul de bile negre extrase cu întoarcere până când se obține o bilă albă.

1.4 Repartiția Pascal(k, p), $k \in \mathbb{N}, p \in (0, 1)$

- ▶ Variabila X are repartiția $Pascal(k, p)$, $k \in \mathbb{N}^+$, $0 < p < 1$ dacă $X =$ numărul de eșecuri până la apariția a k succese într-un șir oarecare de probe Bernoulli independente.
- ▶ Repartiția variabilei $X \sim Pascal(k, p)$, este

$$X: \begin{pmatrix} 0 & 1 & 2 & \dots & x \\ p^k & kp^k q & C_{k+1}^{k-1} p^k q^2 & \dots & C_{x+k-1}^{k-1} p^k q^x \end{pmatrix},$$

$$q = 1 - p, x = 0, 1, 2, \dots \quad (10)$$

- Media și dispersia variabilei X sunt date de formulele

$$E[X] = \frac{kq}{p} \text{ \& \dot{S}i } V(X) = \frac{kq}{p^2}. \quad (11)$$

- *Interpretarea cu urnă:* X numărul de bile negre extrase cu întoarcere până când se obțin k bile albe.

1.5 Repartiția Hipergeometrică(N, p, n) (2)

- ▶ Se definește v.a. X = numărul de bile albe extrase. Spunem că $X \sim H(N, p, n)$.
- ▶ Rezultă $A = \text{round}(Np)$, $B = N - A$.
- ▶ *Probabilitatea* ca în n extrageri succesive fără întoarcere, să se extragă “a” bile albe este:

$$P(X=a) = \frac{C_A^a C_B^{n-a}}{C_N^n}, 0 \leq a \leq n, n < N \quad (14)$$

- Media și dispersia v.a. X sunt date de

$$E[X] = np \text{ \& } \text{Var}(X) = np(1-p) \frac{N-n}{N-1} \quad (15)$$

1.6 Repartiția Poisson(λ) – Algoritm de simulare (2)

- *Repartiția Poisson* poate fi dedusă din *repartiția binomială*. Pentru valori mari ale lui n și mici ale lui p (deci valori modelate pentru np), numărul de succese apărute în n probe poate fi aproximativ de variabilă aleatoare Poisson cu parametrul $\lambda = np$.

- Algoritmul de simulare a v.a. $X \sim \text{Poisson}(\lambda)$:

Pas 1: Se alege o probabilitate $p \approx 0$ (de exemplu, $p = 0.001$)

Pas 2: Se determină $n = \lceil \lambda/p \rceil$

Pas 3: Se simulează $Y \sim \text{Bin}(n, p)$

Pas 4: Se returnează $X = Y$.

1.5 Repartiția Hipergeometrică(N, p, n), $n, N \in \mathbb{N}, n < N, p \in (0, 1)$ (1)

- Considerăm *experimentalul cu urna*: se extrag n bile la întâmplare din urnă *fără întoarcere*.
- Notăm cu u evenimentul: s-a extras o bilă albă și cu v evenimentul: s-a extras o bilă neagră.
- *Probabilitățile de a extrage în prima extragere o bilă albă, respectiv neagră* sunt:

$$p = P(u) = A/N \text{ \textbf{ve} } P(v) = B/N \quad (12)$$

unde A , B reprezintă numărul de bile albe, respectiv negre extrase din urnă, iar N numărul total de bile.

- *Probabilitățile de extragere a unei bile albe sau negre în a doua extragere sunt condiționate de rezultatele primei extrageri:*

$$P(u|u) = \frac{A-1}{N-1}, P(u|v) = \frac{A}{N-1}, \quad (12)$$

$$P(v|u) = \frac{B}{N-1}, P(v|v) = \frac{B-1}{N-1} \quad (13)$$

1.6 Repartiția Poisson(λ), $\lambda > 0$ (1)

- O variabilă aleatoare X este repartizată $Poisson(\lambda)$, $\lambda > 0$ dacă are funcția de probabilitate dată prin

$$P(X=x) = \frac{\lambda^x}{x!} e^{-\lambda}, \lambda > 0 \quad (16)$$

- Media și dispersia variabilei aleatoare $X \sim \text{Poisson}(\lambda)$ sunt

$$E[X] = \lambda \text{ \& \; } V(X) = \lambda. \quad (17)$$

- Repartiția Poisson poate fi utilizată în numeroase aplicații. Câteva situații în care o variabilă aleatoare discretă poate avea o distribuție Poisson sunt:

- ▶ numărul erorilor de tipografie dintr-o pagină;
- ▶ numărul concediilor dintr-o firmă în decursul unei luni
- ▶ numărul defectelor de-a lungul unui fir.

2 Validarea algoritmilor de simulare a unor variabile aleatoare (1)

- ▶ *Algoritm de simulare*: definierea unei v.a. X având o funcție de repartiție dată $F(x) = P(X \leq x)$, $\forall x \in \mathbb{R}$ și observarea variabilei X
- ▶ *Validarea algoritmilor de simulare* înseamnă:
 - ▶ verificarea corectitudinii formale a algoritmilor: se arată că v.a. X construită în algoritm are funcția de repartiție $F(x)$
 - ▶ analiza valorilor de selecție asupra v.a. X returnate de algoritm: pe baza unei mulțimi de selecție X_1, X_2, \dots, X_n , se verifică ipoteza statistică $H_0: X \hookrightarrow F(x)$.

2.1 Histograma – o validare empirică a algoritmului de simulare (1)

- ▶ Se verifică intuitiv dacă *repartiția empirică (de selecție)* este asemănătoare cu cea *teoretică*
- ▶ *Histograma* asociază mulțimii de valori de selecție x_1, \dots, x_n asupra variabilei aleatoare X având funcția de repartiție $F(x)$ și densitatea $f(x)$:
 - ▶ se determină $m = \min\{x_1, x_2, \dots, x_n\}$ și $M = \max\{x_1, x_2, \dots, x_n\}$
 - ▶ se alege k numărul de intervale/dreptunghiuri ale histogramei
 - ▶ se împarte intervalul $[m, M]$ în k intervale egale $I_i = (a_{i-1}, a_i]$, $2 \leq i \leq k$, $I_1 = [a_0, a_1]$, $a_0 = m$, $a_k = M$
 - ▶ se determină frecvențele relative $r_i = \frac{f_i}{n}$, unde f_i : numărul de valori de selecție ce cad în intervalul I_i , $1 \leq i \leq k$
 - ▶ se reprezintă grafic: se iau pe abscisă intervalele I_i și se construiesc dreptunghiurile având ca bază aceste intervale și ca înălțimi $h_i = r_i$.
- ▶ *Înălțimile h_i ale dreptunghiurilor se scalează a.î. $h_i \approx f(x)$, $x \in I_i$. Definim $h_i = \frac{f_i}{nI} \approx f(x)$, $I = a_i - a_{i-1}$.*

◀ ▶ ↻ 🔍

2.2 Test bazat pe momentele de selecție

- ▶ Se determină *momentele teoretice* ale v.a. X :
$$\mu = E[X] \text{ și } \sigma = \text{Var}(X) \quad (21)$$
- ▶ Pe baza mulțimii de valori de selecție $\{x_1, x_2, \dots, x_n\}$ se calculează *momentele de selecție*:
$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \text{ și } s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{X}^2 \quad (22)$$
- ▶ Ca o consecință a *Legii numerelor mari*, putem considera că generatorul este bun dacă pentru n suficient de mare ($n > 1000$)
$$\bar{X} \approx \mu \text{ și } s^2 \approx \sigma^2 \quad (23)$$

◀ ▶ ↻ 🔍

2.3 Testul X^2 (2)

- ▶ Fie α eroarea de tip I: probabilitatea de a respinge ipoteza nulă H_0 când este adevărată. Valorile clasice pentru α sunt 0.01, 0.05, 0.1.
- ▶ Se determină α – *cuantila superioară*, notată $\chi_{k-1,\alpha}^2$ astfel încât
$$P(X^2 \leq \chi_{k-1,\alpha}^2) = 1 - \alpha \quad (25)$$
- ▶ Ipoteza H_0 se *acceptă* dacă în urma experimentului aleator s-a obținut evenimentul $\omega \in \Omega$ a.î.:

$$X^2(\omega) \leq \chi_{k-1,\alpha}^2, \quad (26)$$

în caz contrar se respinge.

◀ ▶ ↻ 🔍

2.1 Histograma – o validare empirică a algoritmului de simulare (2)

- ▶ Din *Teorema lui Bernoulli – forma slabă* rezultă că pentru orice $\epsilon > 0$ avem
$$\lim_{n \rightarrow \infty} P\left(\left|\frac{f_i}{n} - p_i\right| \leq \epsilon\right) = 1, \quad (18)$$
unde $p_i = P(X \in I_i)$, $I_i = a_{i-1}, a_i$
- ▶ Numărul k de dreptunghiuri ale histogramei se consideră a.î. să se minimizeze “*media pătrateror erorilor (MSE)*” estimatorului $\hat{f}(x)$ (definit în orice punct x) al densității de repartiție $f(x)$, definită prin

$$MSE(\hat{f}(x)) = E\left[\left(\hat{f}(x) - f(x)\right)^2\right]. \quad (19)$$

Astfel, avem *Regula Sturges*

$$k = \lceil 1 + \log_2 n \rceil. \quad (20)$$

◀ ▶ ↻ 🔍

2.3 Testul X^2 (1)

- ▶ Considerăm *testul de concordanță X^2* pentru verificarea ipotezei $H_0 : X \hookrightarrow F(x)$.
- ▶ Definim *variabila aleatoare X^2* :
$$X^2 = \sum_{i=1}^k \frac{(f_i - np_i)^2}{np_i} \quad (24)$$
unde $p_1 = F(a_1)$, $p_i = F(a_i) - F(a_{i-1})$, $2 \leq i \leq k-1$, $p_k = 1 - F(a_{k-1})$.
- ▶ *Observații*:
 - ▶ $f_i : \Omega \rightarrow \{0, 1, \dots, n\}$ este o v.a. *Bin* (n, p_i)
 - ▶ Mulțimea tuturor valorilor posibile ale lui X^2 se obține făcând ca f_1, f_2, \dots, f_k să parcurgă toți întregii nenegativi a.î. $\sum_{i=1}^k f_i = n$
 - ▶ Pentru $n \rightarrow \infty$, X^2 este repartizată χ_{k-1}^2 (hi pătrat cu $k-1$ grade de libertate).

◀ ▶ ↻ 🔍

Bibliografie I

- 📖 W. L. Martinez, A. R. Martinez (2002), *Computational Statistics Handbook with MATLAB*, Chapman & Hall/CRC, Boca Raton London New York Washington, D.C.
- 📖 I. Văduva (2004), *Modele de simulare: note de curs*, Editura Universității din București, București

◀ ▶ ↻ 🔍